

ESCRITÓRIO DE PROJETOS E AS ESTIMATIVAS E MÉTRICAS EM TEMPOS DE BIG DATA

Delermundo Branquinho Filho (delermundo@TheScientist.com.br)

RESUMO

Este artigo aborda as estimativas e métricas em gestão de projetos, segundo as melhores práticas descritas no PMBOK © 5ª Edição, e faz uma associação direta entre as ferramentas e técnicas envolvidas nessas estimativas e métricas com a Inteligência Artificial, especificamente na Ciência de Dados. Seleccionamos algumas ferramentas e técnicas do PMBOK para demonstrar como obter os resultados esperados usando algoritmos em Aprendizado de Máquina. Provocamos o leitor a considerar o uso de simuladores além do Monte Carlo. Refletimos sobre o Gerenciamento do Valor Agregado, Árvores de Decisão e Gerenciamento das Partes Interessadas em uma abordagem inovadora na visão da Inteligência Artificial para o gerenciamento de projetos.

1 INTRODUÇÃO

Para uma empresa, ou mesmo para um empreendedor, a melhor coisa que pode acontecer é acertar as estimativas de seus projetos. Como essas estimativas são, na sua maioria, *a priori* e divididas em paramétricas e análogas, sobra muito pouco para ser feito sobre o assunto. Na segunda guerra, com o objetivo de simular os melhores cenários com os menores riscos, o Método de Monte Carlo (MMC) ajudou o Projeto Manhattan. O objetivo naquele momento era resolver problemas de natureza probabilística (HAMMERSLEY, 1964). Os tempos mudaram, os avanços tecnológicos chegaram e novos algoritmos preditivos surgiram.

O objetivo geral desse trabalho é demonstrar que algoritmos em *Big Data* ou em *Data Science* (do inglês Ciência de Dados) podem resolver problemas em estimativas descritas no PMBOK® (PMBOK, 2013, p.338). As ferramentas e técnicas, como por exemplo, Análise de Sensibilidade, Análise do Valor Monetário Esperado e a Modelagem e Simulação serão abordados de acordo com as técnicas inovadoras da Ciência de Dados.

Dentre os objetivos específicos deste trabalho podemos destacar a demonstração de resultados usando-se de outras técnicas de simulação, como por exemplo *Bootstrap*, *Jackknife*, *Árvore de Decisão*, *Random Forest* e Regressão não Linear. Demonstrar outras técnicas mais simples para simulação de estimativas e métricas, pois o MMC pode criar essas estimativas, então é fundamental exercitar tais práticas, já que a simulação de Monte Carlo é pouco usada por causa de sua complexidade (JUNIOR 2001; SABBAG 2015). Completam os objetivos específicos demonstrar que, em tempos de *Big Data*, podemos substituir a complexidade pela simplicidade com as novas tecnologias de estimação e suscitar a inclusão de ferramentas e técnicas em *Data Science* no PMBOK.

Na Seção dois intitulada Conceitos Básicos em Gestão de Projetos abordaremos as estimativas e métricas do PMBOK para a gestão de projetos. Na seção três iremos visitar alguns algoritmos e modelagens que cobrem alguns dos conhecimentos quantitativos, análises gráficas do monitoramento e controle dos resultados do trabalho do projeto. Ao final mostraremos alguns resultados da aplicação direta de algoritmos e modelos em *Data Science* para inovação tecnológica na gestão das partes interessadas.

2 ESTIMATIVAS E MÉTRICAS EM GESTÃO DE PROJETOS

2.1 Estimativas em Gestão de Projetos

Iniciamos essa Seção revisitando as estimativas mais comuns em gestão de projetos. As estimativas análogas, ou *Top-Down* (do inglês de cima para baixo) faz uso da similaridade entre projetos anteriores para determinar os valores para o projeto atual. Muito usada pela maioria dos Gerentes de Projeto por sua facilidade e rapidez. Em contrapartida, ela ocorre quando não temos muitos detalhes e/ou quando a principal restrição é temporal. Outra estimativa *Top-Down* é a Estimativa por Ordem de Grandeza. Nesse caso, as informações que temos são mínimas e temos que nos basear na experiência de um profissional (Opinião Especializada). Segundo o PMBOK, essa estimativa é realizada durante o processo de iniciação e pode representar de -50% até +100% do esforço necessário. Essa margem é muito ampla e deixam muitas possibilidades, o que pode, invariavelmente, aumentar o risco.

As Estimativas Paramétricas são, em sua essência, uma relação estatística entre os dados históricos e outras variáveis do projeto atual, possibilitando assim, a criação de parâmetros, como por exemplo, a probabilidade do custo de uma atividade ficar entre determinados valores. Esse tipo de estimativa pode suportar um alto nível de precisão quando os pacotes de trabalho da EAP (Estrutura Analítica de Projetos), ou as atividades desses pacotes de trabalho são estimados, pois é mais fácil estimar o custo, tempo e recursos de uma atividade quando comparamos estimativas de elementos mais complexos. Aqui podemos perceber que as atividades ou pacotes de trabalho estimados agregam valor nas instâncias superiores da EAP, criando assim as estimativas desses níveis. Os gerentes de projetos, no entanto, devem equilibrar a precisão com o desequilíbrio das restrições do projeto na relação entre Escopo, Qualidade, Cronograma, Orçamento, Recursos e Risco (PMBOK, 2013).

A estimativa PERT (do inglês *Program Evaluation and Review Technique*), que quer dizer literalmente Avaliação do Programa e Técnica de Revisão, é uma das mais usadas e assertivas técnicas de estimativa. Na realidade essa estimativa nasceu em 1950 de forma independente da CPM (do inglês *Critical Path Method*), conhecido como Método do Caminho Crítico. Ambas foram muito usadas em conjunto, o que permitiu dizer por muitos anos que seriam uma técnica e não duas. Neste trabalho faremos um estudo da PERT apenas na Gestão do Valor Agregado (GVA) e no sentido de melhorar o seu desempenho com Aprendizado de Máquina, onde algoritmos preditivos podem aprender o comportamento dessas variáveis e aumentar a acurácia das estimativas preditas (BAEZA-YATES; RIBEIRO-NETO 2013; KIM, 2003; CHEN; CHEN; LIN, 2016).

Se por um lado os projetos ajudam a garantir o sucesso dos empreendimentos os quais ele suporta, boas estimativas ajudam a garantir o sucesso dos projetos em que as mesmas suportam. Uma hipótese plausível poderia ser: se temos estimativas que se aproximam dos valores reais, então temos a vantagem competitiva de errar menos e ter mais sucesso em nossos projetos, no entanto, esse trabalho não tem a intensão de provar essa hipótese.

2.2 Métricas em Gestão de Projetos

Quanto as Métricas, podemos destacar algumas cujo monitoramento é fundamental. A Produtividade é uma dessas métricas, onde o esforço planejado deve ficar próximo ao esforço realizado. Todas as métricas atuam nas seis restrições e podem afetar a produção. A Linha de Base do Escopo é, de certa forma, uma métrica empírica definida nos primeiros momentos do planejamento do projeto. Como os projetos são planejados em Ondas Sucessivas (PMBOK, 2015, p.45), temos a vantagem de conhecermos mais

sobre ele com o avanço do tempo, mas temos também a desvantagem de sofrer alterações por conta de restrições e dependências entre outras variáveis que provocam mudanças.

A Qualidade sem dúvida é uma das mais controladas e monitoradas dentro dos projetos, pois é ela é uma métrica importante que ajuda a garantir as entregas. A correta definição e monitoramento dessa métrica permite detectar erros e anomalias que podem comprometer o equilíbrio das seis restrições no projeto.

O Cronograma é a última métrica que iremos abordar neste trabalho. Essa métrica tem como base a comparação da data alvo com a data planejada. Podemos expandir as datas de conclusão planejadas para pacotes de trabalho, atividades ou qualquer outro ponto de término. Podemos ainda acrescentar em nossa entrada de dados, ou colunas de nosso *dataset* (arquivo de trabalho dos cientistas de dados), qualquer nível de granularidade.

Para finalizar a lista, como uma sequência natural da métrica Cronograma, abordaremos o Custo e a Margem Bruta. O primeiro podemos dividi-lo em Custo Real (CR), Valor Agregado (VA) e Valor Planejado (VP). Já o segundo é uma constante monitorada para medir o real desempenho do projeto.

3 DATA SCIENCE NA GESTÃO DE PROJETOS

3.1 Estimativas e Métricas em Big Data

Medir é, além de obrigatório em gestão de projetos, algo comum na administração de um modo geral, pois conforme a célebre fala de Edwards Deming:

*“Não se **gerencia** o que não se **mede**,
não se **mede** o que não se **define**,
não se **define** o que não se **entende**,
e não há **sucesso** no que não se **gerencia**”*
(William Edwards Deming)

Relacionamos, nas seções anteriores, as estimativas e métricas e a sua importância fundamental para o controle dos projetos, sem esquecer que esse controle passa por medições. Poderíamos ter listado outras estimativas e métricas em gestão de projetos, mas para exemplificar o uso de algoritmos em *Data Science* ficamos com as principais e elas são suficientes para esse propósito. Em Ciência de Dados no contexto Big Data, a medição são coletas de dados, o tratamento e a transformação do dado e *dataset*, a definição são os modelos, o entendimento o Aprendizado de Máquina (*Machine Learning*) entre outros algoritmos (BAEZA-YATES; RIBEIRO-NETO 2013).

Data Science é uma expressão associada ao processo de transformação de dados (PROVOST; FAWCETT, 2013). Para isso é preciso criar modelos que descrevam as relações existentes entre os dados e suas influências. Objetiva-se saber como esse comportamento pode direcionar o sucesso dos empreendimentos e então, usar análises preditivas sobre as nossas estimativas e métricas.

Um bom exemplo de uso de *Data Science* em Escritórios de Projetos é a Árvore de Decisão. Na Figura 11-16 do PMBOK (PMBOK 2013. p.338) temos um exemplo de análise do valor monetário esperado. Essa análise pode ser feita usando a mesma técnica em *Data Science*. Apenas para exemplificar, há vários pacotes disponíveis em várias linguagens de programação, onde passamos os parâmetros e obtemos a mesma árvore exemplificada no PMBOK já com as melhores opções.

Em qualquer empreendimento, os patrocinadores e partes interessadas estão muito preocupados com os resultados das estimativas, principalmente porque essas estimativas são *a priori*, ou seja, elas ainda não se confirmaram. Como estimativas, há uma variação quando ocorre sua confirmação. Isso fica claro quando falamos do custo

real (CR) e do valor agregado (VA) em relação ao valor planejado (VP). Se pudermos prever, com boa margem de exatidão, os valores de nossas estimativas e métricas, além do ROI (Retorno do Investimento) e TCO (Custo Total de Propriedade), então estaremos contribuindo para a melhoria do desempenho em nossos projetos.

3.2 Criando Modelos Preditivos

A capacidade de prever eventos futuros é, sem dúvida, uma funcionalidade almejada por todos os gestores em qualquer indústria. A predição de índices de desempenho futuro já está sendo estudada por vários pesquisadores (CHEN;CHEN;LIN, 2016). A ciência tenta explicar eventos do passado ao longo do tempo como forma de prever esses eventos no futuro. Essa técnica é conhecida como *Time Series* ou Séries Temporais (KIM, 2003). A Simulação de Monte Calo é uma das mais conhecidas, mas como dissemos anteriormente, muito pouco usada no dia-a-dia em projetos por causa de sua complexidade (BARRETO; ANDRADE, 2014).

Para exemplificar a possibilidade de uso de outros modelos, criamos um cenário para demonstração desse tipo de predição sem envolver a Simulação de Monte Carlo. Usaremos o modelo linear generalizado (GLM do inglês *Generalized Linear Model*). Esse modelo é uma generalização da regressão linear tradicional e permite variáveis de resposta que possuem modelos de distribuição de erros diferentes de uma distribuição normal ou Gaussiana.

O GLM generaliza a regressão linear e, em nosso caso, adicionaremos a Regressão Polinomial ou Quadrática, pois esse tipo de regressão, diferente da linear, permite representar os modelos de resposta curvilínea, já que nossa Curva-S (PMBOK, 2013. p.219) obedece esse fenômeno.




Figura 1 - Gestão do Valor Agregado (GVA) Real x Predito

Na Figura-1 temos dois gráficos, no lado esquerdo estão representados os dados com valores realizados (Real) para o VA e CR, do lado direito foram adicionados os valores previstos (Predito), ambos de acordo com desempenho atual e com 50% do trabalho realizado com uma duração total de 100 dias. Os valores desses gráficos foram criados da técnica de simulação *Bootstrap* para seleção do melhor cenário dentro das distribuições normais ou Gaussianas, pois levamos em consideração a relação ao gráfico da Figura 2-8 da página 38 do PMBOK, onde a execução do projeto consome a maioria dos recursos e as caldas da curva ficam com as menores frequências.

As representações gráficas são complementares, sendo que o gráfico à direita completa o gráfico à esquerda com valores preditos em caixa alta na legenda (GVA). É fácil observar que o projeto passou por dificuldades entre os dias 16 e 37, isso refletiu no custo real na segunda metade do projeto. O objetivo foi encontrar o melhor cenário de entrega. Não se pode deixar de observar que apenas a curva do custo real está distante das demais. As curvas de predição do valor agregado e planejado seguem a tendência da curva do Valor Planejado. Para os valores do gráfico Predito nós usamos a GLM com formulação quadrática. Par garantir as entregas representamos as novas curvas como *Predito*.

Com esse modelo de previsão do GVA podemos visualizar como será o desempenho do nosso projeto, receber avisos e alertas em caso de problemas ou desvios fora da curva antecipadamente através de simulações (*Bootstrap*) e escolhendo aquele com o menor risco. Além do GVA outros valores, lembrando que os índices e métricas descritos na seção dois podem ser preditos usando esse modelo (GLM Polinomial), há outros modelos de regressão com finalidades outras que podem ser mesclados e usados para testar o melhor desempenho de um projeto com determinadas características, outro projeto com atributos diferentes pode exigir outros modelos. Será preciso testar alguns algoritmos e medir a sua acurácia para selecionar o melhor para aquele cenário. Isso nos remete ao fato de aprimorar os estudos e sistemas em *Big Data* para a Gestão de Projetos, especialmente quando falamos de Sistemas de Gerenciamento de Projetos (SGP).

O PMBOK está repleto de exemplos (PMBOK 2013, p.239) onde podemos usar *Machine Learning* entre outros campos de estudo da Ciência da Computação e Inteligência Artificial. O uso de gráficos exploratórios em *data Science* se confunde com os Histogramas, Diagramas de Dispersão, Diagramas de Pareto entre outros gráficos de controle presentes no PMBOK e que são oriundos de estudos estatísticos. Por sua vez, o Aprendizado de Máquina evoluiu do estudo de reconhecimento de padrões e da teoria da aprendizagem computacional incorporando-se hoje aos processos organizacionais (MICHALSKI; CARBONELL; MITCHELL, 2013).

Outro modelo para predição intimamente ligado com Escritórios de Projetos encontra-se na página 145 do PMBOK. Selecionamos o gráfico do programa do processo de decisão (GGPD). Para esse artigo vamos nos restringir a apenas esse exemplo. Vamos demonstrar a Análise do Valor Monetário Esperado (VME) conforme descrito no próprio PMBOK “[...] é um conceito estatístico que calcula o resultado médio quando o futuro inclui cenários que podem ocorrer ou não (ou seja, análise em situações de incerteza).” (PMBOK, 2013. p.338). A Figura-2 mostra esse Diagrama da Árvore de Decisão.

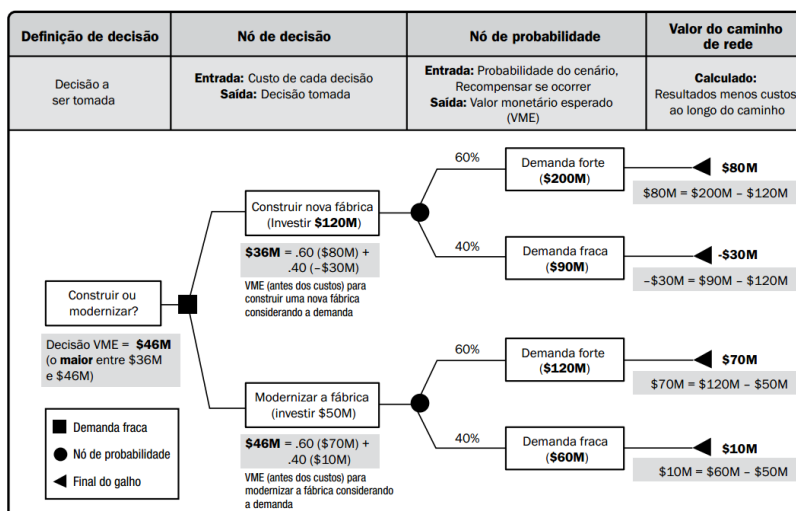


Figura-2 - Árvore de Decisão - PMBOK Figura 11-16 (2013, p.338)

Apesar do exemplo didático do PMBOK ajudar o entendimento, na vida real as decisões contemplam um número maior e variado de atributos a serem considerados nas decisões. Vamos reproduzir esse exemplo usando *Machine Learning*. O Algoritmo é o mesmo *Decision Tree*.

As variáveis *investimento* e *demand*a foram retiradas originalmente do problema descrito no diagrama anterior da Figura-2. A indicação do *p-value*, na Figura-4 abaixo, menor do que 0,001 é um indicativo estatístico clássico, também chamado de nível descritivo ou probabilidade de significância (ARSHA, 1988). Quando esse valor é igual ou superior a 0,05 significa que você não tem evidências suficientes para suportar suas crenças (Hipótese Nula). Em nosso caso o *p-value* é muito pequeno, corroborando assim nossos resultados.

Os Valores Monetários Esperados no diagrama de árvore apresentados no PMBOK ficam entre \$36 e \$46, esses dados foram inseridos em um *dataset* (configuração de dados para processamento em *Data Science*) contendo as probabilidades, os valores de modernização e construção, além dos valores demanda.

Em uma situação real, outros atributos podem estar presentes podendo passar de dezenas ou centenas (PROVOST; FAWCETT, 2013) o que aumenta sobremaneira os ramos e consequentemente a complexidade. O cálculo realizado na Figura-2 leva em consideração as medidas de tendência central, em nosso exemplo na Figura-4, uma classe não-paramétrica de incorporação de árvores de regressão.

```
1 base <- read.csv("base.txt",header = TRUE,sep = ";")
2 library("partykit")
3 ct <- ctree(retorno ~ vme + investimento + demanda , data = base)
4 plot(ct)
5
```

Figura 3 - Linhas de código na Linguagem R

As linhas de comando acima geram o diagrama da Figura-4. Os dados foram carregados a partir do *dataset base.txt*. Inserimos o código para mostrar ao leitor a simplicidade da aplicação e o resultado obtido com essas quatro linhas de instrução.

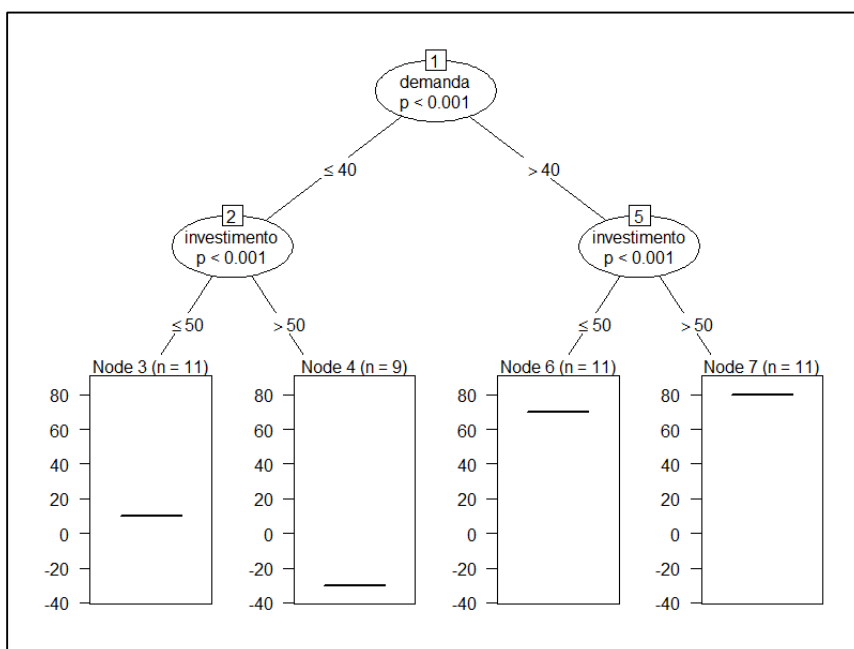


Figura 4 - Diagrama em *Decision Tree*

No diagrama acima observa-se os mesmos resultados no diagrama anterior, notadamente, a demanda é a principal variável dessa equação. Observa-se também a facilidade de interpretação dos resultados. A recomendação é a mesma descrita no PMBOK com as respostas \$10 e \$70 para os *nodes* três e seis relativos à modernização e \$-30,e \$80 para os *nodes* quatro e sete relativos à construção de uma nova fábrica.

Alguns podem pensar que o gerenciamento das partes interessadas poderia ficar de fora desta abordagem em *Data Science* para Gestão de Projetos, mas há estudos avançados que agregam valor nesse gerenciamento com o uso de modelos e algoritmos em *Data Science*, muito além da Matriz RACI e das técnicas analíticas (CASTRO-HERRERA; CLELAND-HUANG, 2009; BARAN; JANTUNEN, 2004). É possível medir o nível de engajamento das partes interessadas e isso não é recente (BOHUS; HORVITZ, 2009).

Suponha que estamos procurando fazer uma análise de nossas partes interessadas para potenciais problemas ou para a análise de risco. Precisamos entender os vários modelos classificatórios, como por exemplo, o grau de poder, interesse, influência e impacto. Segundo o PMBOK o “Modelo de Relevância descreve os tipos de partes interessadas com base no seu poder (capacidade de impor sua vontade), na urgência (necessidade de atenção imediata) e na legitimidade (seu envolvimento é apropriado).”. (PMBOK 2013. p.395). Essas classificações juntas criam um vetor de características para serem usados como métricas de centralidade de proximidade e *Farness* explicados mais adiante.

Podemos incluir na gestão das partes interessadas tratamentos similares às de uma rede social, nesse caso, em *Data Science* queremos extrair uma métrica chamada centralidade de proximidade (*Closeness Centrality*). As métricas de centralidade tentam aproximar uma medida de influência de um indivíduo dentro de uma rede. A distância entre dois vértices (cada vértice v é um Stakeholder) é o caminho mais curto. A *Farness* é a propriedade criada pelo espaço entre duas partes interessadas ou pontos da rede. A *Farness* de um determinado vértice v é a soma de todas as distâncias de cada vértice para v . Finalmente, a proximidade de um vértice v é o inverso da *Farness*. Em outras palavras queremos saber quem influencia quem dentro da rede, quais são os grupos e como eles se relacionam.

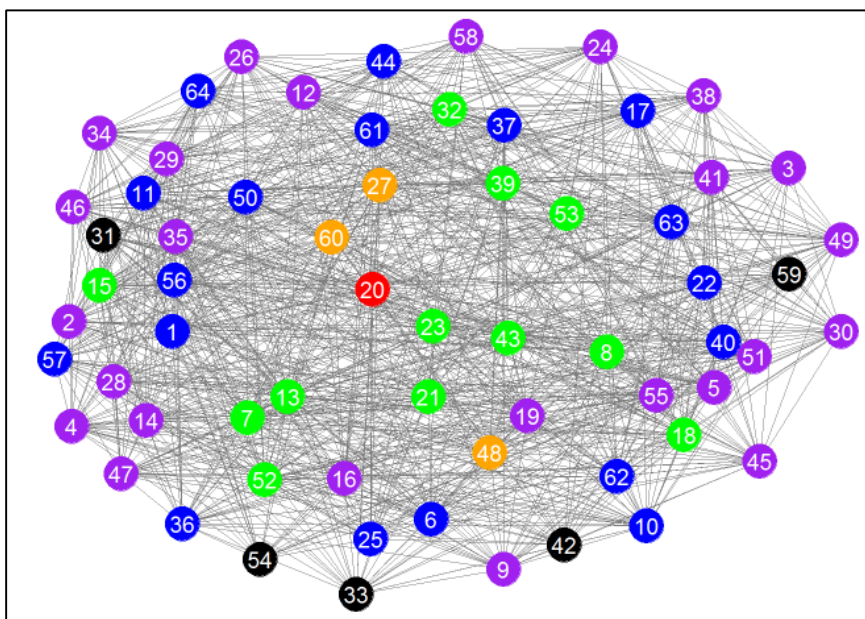


Figura 5 - Infográfico do interesse, influência e poder dos *Stakeholders*

No infográfico da Figura-5 a parte interessada de número 20 é aquela com o maior poder e influência para o projeto em questão. Esse *infográfico* deve ser usado em parceria com o gráfico da Figura 13-4 do PMBOK (PMBOK, 2013. p.397) onde a informação de gerenciar com atenção deve ser anotada. É possível usar esse mesmo infográfico para determinar quais partes interessadas devem ser mantidas satisfeitas, informadas ou apenas monitoradas.

Um bom exemplo da análise é o Stakeholder #15, ele está distante do seu grupo no projeto com *Farness* menor e perto de outras partes interessadas com uma *Farness* maior. Quanto mais distante do centro, menor é a conjunção dos fatores de influência e impacto. As cores distinguem os grupos com atributos ou características semelhantes. É uma forma de agrupamento que em *Data Science* chamamos de *Clusters*. Em projetos grandes com centenas de partes interessadas essa ferramenta pode mapear e entregar resultados mais realistas, com menor tempo e esforço para a equipe de projetos.

4 CONCLUSÃO

4.1 Considerações Finais

Conforme demonstrado, poderíamos suportar todas as métricas e estimativas, bem como a exploração, amostras, estatísticas dos gráficos de controle, *Benchmarking*, o Método do Caminho Crítico (MCC) contendo as variáveis de início mais cedo, mais tarde e término mais cedo e mais tarde, todos sendo submetidos a algoritmos e modelos com o objetivo de se obter o melhor cenário para o monitoramento e o controle do desempenho do trabalho.

Se levarmos em consideração que o MCC pode variar muito dentro de projetos de médio e grande porte, criar múltiplos cenários com suas dependências pode ser uma tarefa árdua. Podemos usar técnicas e modelos dentro das melhores práticas do PMBOK através de técnicas de amostragem, como por exemplo *Bootstrap* ou *Jackknife*, podemos gerar esses cenários para uma análise de riscos, sem ter a necessidade de usar a Simulação de Monte Carlo, bem mais complexa e com os mesmos resultados (SNOEK; LAROCHELLE; ADAMS, 2012).

A diversidade de soluções em *Data Science* com soluções para os problemas em gerenciamento de projetos é grande e vem aumentando a cada dia. Novos algoritmos estão sendo construídos e testados. Devemos pensar que a cerca de 20 anos atrás a Inteligência Artificial estava restrita a estudos acadêmicos, mas hoje ela invadiu as empresas, alterando suas estratégias e modificando os conceitos de tecnologias maduras, como por exemplo BI (*Business Intelligence*, do inglês inteligência de negócios) que agora se transforma em *Business Analytics* (LARSON; CHANG, 2016; CHEN; CHIANG; HL; STOREY 2012).

4.2 Trabalhos Futuros

Com o avanço do *Big Data*, do *Data Science* e da Inteligência Artificial, os projetos serão mais desafiadores, pois o volume de dados e variáveis a serem controlados aumentará sistematicamente cada vez mais. Dados históricos agora ganham um papel fundamental para a melhoria das estimativas preditivas, pois não podemos confiar apenas nas medidas de tendência central, como por exemplo a média e variância, na busca de uma maior assertividade nas decisões.

O ideal é que as empresas fornecedoras de sistemas para gerenciamento de projetos comecem a inserir em suas funcionalidades, agentes inteligentes para predição, a exemplo do que foi feito neste artigo. Quanto maior for o número de funcionalidades e opções para o assertivo monitoramento e controle das variáveis dos projetos, maior serão as chances de um ROI satisfatório do empreendimento.

Não podemos esquecer de mencionar os profissionais envolvidos no gerenciamento de projetos, e não estamos limitados apenas a equipe do projeto, mas consideramos que o treinamento é parte fundamental do amadurecimento da Ciência de Dados nas organizações, do entendimento à solução dos problemas, uma nova faceta colaborando para o aprimoramento e melhoria do desempenho.

Podemos supor que a popularização das técnicas, algoritmos e modelos discutidos aqui, dentre tantos outros, possam futuramente fazer parte do PMBOK, ajudando assim, cada vez mais, os profissionais envolvidos e comprometidos com os empreendimentos das empresas materializados em seus projetos.

BIBLIOGRAFIA

ARSHA, H Kuiper's. **P-value as a Measuring Tool and Decision Procedure for the Goodness-of-fit Test**, Journal of Applied Statistics, Vol. 15, No.3, 131-135, 1988.

BAEZA-YATES; RIBEIRO-NETO. **Modern information retrieval: The concepts and technology behind search**. New York: ACM Press, 2013.

BARAN, Eric; JANTUNEN, Teemu. **Stakeholder consultation for Bayesian decision support systems in environmental management**. Forest, v. 27, n. 35.6, p. 37.1, 2004.

BARRETO, Guilherme de A; ANDRADE, Marinho de A. **Estimação Paramétrica de Modelos Auto regressivos via Estatística Bayesiana e Simulação de Monte Carlo**. São Carlos. USP 2014. Disponível em 04/07/2017

BOHUS, Dan; HORVITZ, Eric. **Learning to predict engagement with a spoken dialog system in open-world settings**. In: Proceedings of the SIGDIAL 2009 Conference: The 10th Annual Meeting of the Special Interest Group on Discourse and Dialogue. Association for Computational Linguistics, 2009. p. 244-252.

CASTRO-HERRERA, Carlos; CLELAND-HUANG, Jane. **A machine learning approach for identifying expert stakeholders**. In: Managing Requirements Knowledge (MARK), 2009 Second International Workshop on. IEEE, 2009. p. 45-49.

CHEN, Hong Long; CHEN, Wei Tong; LIN, Ying Lien. **Earned value project management: Improving the predictive power of planned value**. International Journal of Project Management, v. 34, n. 1, p. 22-29, 2016.

CHEN, Hsinchun; CHIANG, Roger HL; STOREY, Veda C. **Business intelligence and analytics: From big data to big impact**. MIS quarterly, v. 36, n. 4, 2012.

HAMMERSLEY, John Michael; HANDSCOMB, David Christopher. **Monte Carlo Methods**. Methuen; J. Wiley, 1964.

http://www.academia.edu/download/43503075/ESTIMAO_PARAMTRICA_DE_MODELOS_AUTO-REGRE20160308-12567-1yxvb1n.pdf

JORION, P. **Value at Risk: A nova fonte de referência para o controle do risco de mercado**. São Paulo: Bolsa de Mercadorias e Futuros, 1997.

JÚNIOR, DUARTE; MARCOS, Antonio. **AM Risco: definições, tipos, medição e recomendações para seu gerenciamento**. Gestão de risco e Derivativos. São Paulo: Atlas, 2001.

KIM, Kyoung-jae. **Financial time series forecasting using support vector machines**. Neurocomputing, v. 55, n. 1, p. 307-319, 2003.

LARSON, Deanne; CHANG, Victor. **A review and future direction of agile, business intelligence, analytics and data science.** International Journal of Information Management, v. 36, n. 5, p. 700-710, 2016.

MICHALSKI, Ryszard S.; CARBONELL, Jaime G.; MITCHELL, Tom M. (Ed.). **Machine learning: An artificial intelligence approach.** Springer Science & Business Media, 2013.

PMI. **PMBOK (®) Guide.** Ed. 5ª. Project Management Institute, 2013.

PROVOST, Foster; FAWCETT, Tom. **Data science and its relationship to big data and data-driven decision making.** Big Data, v. 1, n. 1, p. 51-59, 2013.

SABBAG, Omar Jorge; COSTA, Silvia Maria Almeida Lima. **Análise de custos da produção de leite: aplicação do método de Monte Carlo.** Extensão Rural, Santa Maria, v. 22, n. 1, p. 125-145, 2015.

SNOEK, Jasper; LAROCHELLE, Hugo; ADAMS, Ryan P. **Practical bayesian optimization of machine learning algorithms.** In: Advances in neural information processing systems. 2012. p. 2951-2959.